

大規模言語モデルによる投稿の意味的連続性判定手法

林 想汰[†] 小林 亜樹^{††}

[†] 工学院大学情報学部情報通信工学科 〒163-8677 東京都新宿区西新宿 1-24-2

^{††} 工学院大学 情報学部情報通信工学科 〒163-8677 東京都新宿区西新宿 1-24-2

E-mail: [†]tj020216@ns.kogakuin.ac.jp, ^{††}aki@cc.kogakuin.ac.jp

あらまし 文書解析において一定の主題に関する会話文を対象とする場合があるが、一般に会話の主題はその途中で変化するため、同一の主題についての会話部分のみを抽出する必要がある。本稿では、大規模言語モデル (Large language model; LLM) を用いて、会話文の主題が同一のままであるか転換されたかを判別する手法について提案する。連続する会話文を対象とし、その内容が意味的に継続しているかを尋ねるような問い合わせ文とともに LLM への入力として、その結果を得ることで判定する。Twitter の reply tweet ペアを用いた判定実験を行い、有効性などを検証する。
キーワード LLM, 文書解析, 会話, データベース, ソーシャルメディア

1 はじめに

近年 SNS などのソーシャルメディア上での商品評判情報の分析は、現代において極めて重要な役割を果たしている。顧客は自身の意見や感想を即座に共有し、他のユーザーとのやりとりを容易に行うことができるため、企業はこれらの SNS 上での評判を積極的に分析することが求められる。顧客の意見を収集・分析することで、企業は製品の欠点や改善点を把握し、顧客満足度を向上させることができる。さらに肯定的な投稿がされると、製品やサービスのプロモーションにも繋がり、新規顧客の獲得に寄与する可能性がある。また、これらの商品情報は reply 機能等での会話中に商品評判情報が含まれる場合もある。しかし、一般に会話中では所々で話題が転換するため、特定の主題についてのテキストは会話全体の一部である。そのため長い継続会話内で特定の主題であるかを識別することや抽出を行うことが必要となり、会話テキストにおいて話題の転換点を見つけ出せれば主題部分の切り出しに寄与できる。

近年、大規模言語モデル (LLM) の発達が著しく、大規模言語モデルがコンテキストを理解できることから、さまざまなテキスト分析に応用できる。大規模言語モデルは、文の前後の文脈を考慮し、単語やフレーズの意味や関係性を理解する能力を持っており、テキストデータから意味の抽出や類似性の判定、情報の要約など、さまざまな分析タスクに適用することが可能である。

本研究では SNS 等の会話テキストにおいて特定主題文の切り出しを行い、SNS 上の reply 文ペアについて話題が継続しているかの判定を行うことを目的とし、LLM により、文ペアの各文の話題が「同一」「異なる」の判定を行わせ、会話の継続/非継続の判定を行う手法を提案する。提案手法では、複数のやりとりの会話文から 2 回のやりとりのみを抜き出し前処理を行う、前処理後の会話文、会話文とその会話文が継続しているかの答えを含む例題と一緒にプロンプト文を作成する。パラメータを設定して、LLM に与えて回答文から判定結果を抽出する。

あらかじめ作成した正解ラベルとの比較を行う。プロンプトで与える例題の種類を変えて会話の継続正判定への影響を調査し、本論文で設定するパラメータ組から有効性の検証を行う。

2 関連研究

SNS に投稿されたデータを用いた研究は多くあるが、話題の継続性を検出する研究は少ない。対話に着目した研究では対話破綻検出チャレンジが提供するデータセットである DBDC データセット [1] を用いた研究がある。DBDC データセットは 1,2 は日本語のみだったが 3 からは日本語と英語の両方に対応している。データセットは人間と対話システムによる 2 者間の対話とそれぞれの対話にアノテーターが付与したラベルによって構成されている。ラベルは破綻ではない、破綻とは言い切れないが、違和感を感じる発話、あきらかに破綻している発話、の 3 種類の内どれかのラベルが付与されている。付与は 30 人のアノテーター達の多数決によって決められ、違和感を感じる発話と破綻している発話の割合が 0.5 を超えなかったものに関しては破綻ではないのラベルを付与している。DBDC データセット 1 は 100 の雑談対話が集められ、DBDC データセット 2 は DCM, DIT, IRS の 3 つの雑談対話システムからそれぞれ 100 対話ずつ集められ合計 300 対話で構成されている。

LSTM を中間層に用いた RNN による対話検出手法 [2] では対話破綻検出チャレンジで配布された条件付き確率場を用いた検出手法と比較してあきらかに破綻の検出精度は高かったが違和感を感じる発話とあきらかに破綻の検出精度では低い結果となっていた。また、QRNN で対話モデルの学習を行い対話モデルを用いた対話破綻検出器を提案した手法 [3] では、対話モデルの学習に RNN を用いた対話破綻検出器の手法と比べて学習速度が 3.2 倍高速化し検出精度の改善を示していた。しかしこれらの研究では対話が破綻しているかしていないかという点には着目しているが実際に SNS に投稿されたデータを用いて実験は行っていない。

また、SNS のデータを利用した研究では災害情報の採取に着

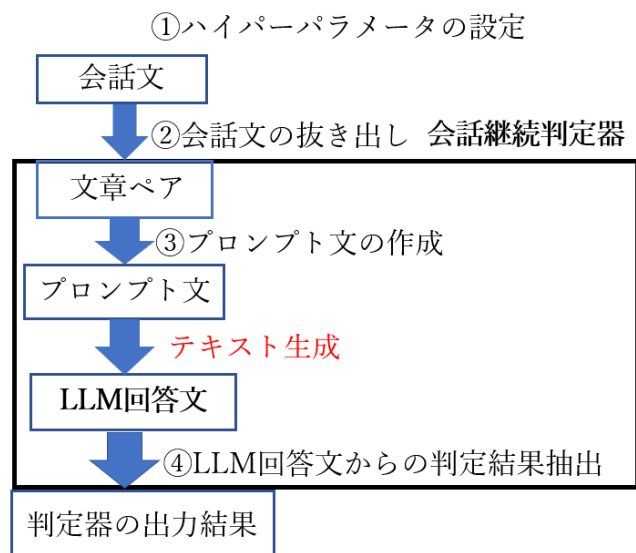


図 1: 提案手法概要図

目した藤田ら [4] の研究がある。この研究では情報を採取する採取者による教師データを必要とせず自己教師学習による準リアルタイムでの採取の手法を提案した。Twitter は投稿できる文字数が 140 文字以内で短文であることから分類は困難であったが、複数のつながった tweet を 1 つの会話文章と見なし、かつその会話内でも分析を行うことも提案した。この手法では代表語が含まれているかどうかでの分類を行う比較手法と比べて精度が良く会話内の部分単位での分析が有効であることを明らかにした。しかし特定の単語のみの採集は可能であるが汎用的にさまざまな情報を採取出来るものではなかった。

本研究では SNS に投稿されたデータでつながりのある投稿群を会話のやりとりとみなし、それらの会話間においての話題の継続性を LLM を用いて判定することを目的とする。

3 提案手法

3.1 概要

本論文では、一連の会話等の連続したやりとりのテキストにおいて、話題の転換点を見つけ出すことで何らかの主題についての一連のテキストを抽出する方針を考える。そこで、話題の転換点を、やりとりのうち異なる話者から発せられた連続した 2 文（ここでは、会話中の 1 発言などの区切りを 1 文と呼ぶ）の言及している主題が同一であるか異なるかを識別する問題を解くこととする。このとき、2 文中の後続文が先行文と同一の話題であることを話題が継続するといい、異なることを話題が非継続であるという。

この連続する 2 文における話題継続性問題を解く判定器の構成を提案する。提案する判定器は LLM の機能を利用し、話題判定器の振る舞いを指示する文と、判定対象文とを LLM への入力プロンプト文とする。LLM の生成した出力文から判定結果のみを抽出することで、最終的な話題継続性の判定結果を得る。図 1 がその処理の概要図である。判定は連続する 2 文である会話文である。これをプロンプト文に変換するにあたり必要

な前処理を行う。前処理後の 2 文の組のことを文章ペアと呼ぶ。これに 3.4 節で述べる指示文を組み合わせてプロンプト文を作成し、LLM への入力とする。LLM 自体は別に設定しておいたハイパーパラメータに従い、入力プロンプト文の指示により出力文を生成する。出力された文を LLM 回答文とよぶが、ここにはプロンプト文だけでは制御しきれない不要な文字列が含まれているため、別に判定結果のみを抽出するフィルタを適用して、最終的な判定結果とする。

3.2 ハイパーパラメータの設定

LLM はテキストを生成する際に生成する文章に変化を与えるものとしてプロンプト文とハイパーパラメータがあげられる。そのなかでもハイパーパラメータを具体的な数値で設定することにより生成させる文章を細かく変えることが可能となる。特に日本語は語順の自由度が高く、1 つの文章内にひらがなや漢字など多くの文字が使われることから複雑かつ表現力が高いテキストを生成することが可能である。

LLM の運用に当たっては数々のハイパーパラメータが設定されるが、本研究では出力文の生成に大きな影響を及ぼす特に 2 つのパラメータについてその値を細かく見ていく。一つ目は `max_new_tokens` と呼ばれる生成文のトークン数を制限するパラメータであり、これは、経験的に 10 に設定しておく。これは生成するテキストのトークン数が大きい場合、判定に必要な情報以外も生成されてしまい判定結果に影響を及ぼしてしまうことを防ぐ点や、判定結果が継続判定なのか非継続判定なのかを絞りやすくするためである。二つ目は生成するテキストのランダム性を操作できる `temperature` の値である。このハイパーパラメータを設定を高く設定することにより生成するテキストが創造的な内容になり、低く設定することにより現実的な内容になる。この `temperature` の値については 5 章において複数の値について試行して、判定器の性能に与える影響を検証していく。

3.3 会話文の抜き出し

LLM に判定させたい複数回のやりとりのある会話文を用意する。そのうち会話の始まりの文章とそれに続く 2 つ目の文章のみを抜き出す。ここでは LLM に判定させる対象の会話文章 2 つを 1 組としたときにその文章集合のことを文章ペアと呼ぶ。また、文章ペアのうち LLM に入力する際に先に与える会話文章を先行文、そのあとに与える会話文章を後続文と定義する。

3.4 プロンプト文の作成

生成されるテキストはプロンプト文の内容によっても左右される。そのためいくつかあるプロンプトの書き方においてどの書き方を選びどのように与えるかが重要となる。プロンプトの記法として `shot 文` [5] と呼ばれるプロンプト内に与えるタスクの例題とその回答を示すことで生成されるテキストの精度を向上させるプロンプティング手法が知られている。また、このとき LLM にプロンプトとして与える際に提示する例題のことを本研究では継続性判定例題と呼ぶ。そのうち話題が継続している例題を継続例題、話題が継続していない判定例を非継続例題と呼ぶ。本研究では異なる `shot 文` による複数のプロンプト文を

例 1 プロンプト作成例

入力 先行文:寝過ぎて体が痛いのだがまだ熱が下がらない副反応でここまで引張るの予想外だわ、後続文:三回目がモデルナだと、やや強く服反応が出るそうですね。お大事にです！

出力

- 1: 以下は、タスクを説明する指示です. 要求を適切に満たす応答を書きなさい.
- 2: ### 指示:
- 3: 回答は YES か NO だけで出力してください. 以下の 2 つの文の話題が続いているかどうか判定してください. 判定例は次のとおりです.
- 4: 1 文目:ブチャラティ、おかっぱのくせにかっこよすぎるな
- 5: 2 文目:そりゃ世界一かっこいいおかっぱだから
- 6: 判定結果:YES
- 7: 1 文目:寝過ぎて体が痛いのだがまだ熱が下がらない副反応でここまで引張るの予想外だわ
- 8: 2 文目:三回目がモデルナだと、やや強く服反応が出るそうですね。お大事にです！
- 9: ### 判定結果:

作成し、shot 文の種類毎による回答精度など判定に及ぼす影響について調査する。さらに、判定結果を集計しやすくするために判定結果は YES か NO のどちらかだけが出力されるように指示する。

ここからプロンプトの作成手順を説明する。例 1 として実際に使用したプロンプト作成例を示す。3.3 にて抜き出した文章ペアを用いる。出力の 4 行目が継続性判定例題の先行文、5 行目が継続性判定例題の後続文、6 行目が継続性判定例題の答えである。7 行目が実際に判定させたい文書ペアの先行文で 8 行目がその後続文である。9 行目の「判定結果:」の後に LLM にテキストを生成させる。このような形式でプロンプトを作成する。例題数を増やす際には 4 行目から 6 行目のような例題が 7 行目以降に記述される。この形式に判定させたい文章ペアや継続性判定例題を変えることでプロンプト文の作成を行う。

3.5 LLM 回答文からの判定結果抽出

LLM 回答文は入力文である命令文や判定対象の会話文などを含むプロンプト文の後に続く形で生成される。また、判定器の結果として基本的には Positive(会話が継続している),Negative(会話が継続していない)のどちらかだけが出力され意味が 1 つに定まるような結果が望ましい。そのために出力結果をそのまま用いるのではなく加工する必要がある。

LLM 回答文を処理する際の概要図として図 2 を示す。3.4 にて作成したプロンプト文を用いて判定結果のみの抽出手順を説明する。まず、文章ペア間においての話題が継続しているかどうかの判定を行う。その結果プロンプト文を含む形で LLM 回答文が生成される。例 2 として出力結果を示す。抽出は以下の手順で行う。

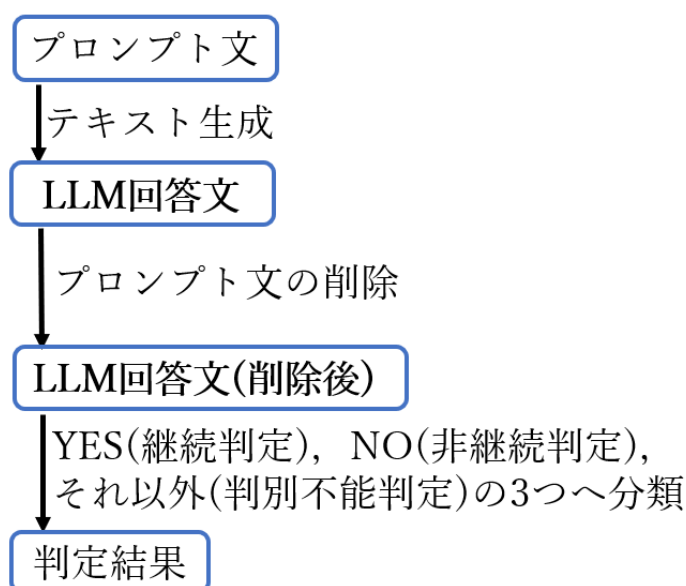


図 2: 出力テキスト処理フローチャート

例 2 出力結果

出力

- 1: 以下は、タスクを説明する指示です. 要求を適切に満たす応答を書きなさい.
- 2: ### 指示:
- 3: 回答は YES か NO だけで出力してください. 以下の 2 つの文の話題が続いているかどうか判定してください. 判定例は次のとおりです.
- 4: 1 文目:ブチャラティ、おかっぱのくせにかっこよすぎるな
- 5: 2 文目:そりゃ世界一かっこいいおかっぱだから
- 6: 判定結果:YES
- 7: 1 文目:寝過ぎて体が痛いのだがまだ熱が下がらない副反応でここまで引張るの予想外だわ
- 8: 2 文目:三回目がモデルナだと、やや強く服反応が出るそうですね。お大事にです！
- 9: ### 判定結果:YES

(1) まず、1 行目から 9 行目の「判定結果:」まではプロンプト文であり、この部分が存在すると判定結果が誤判定になってしまうため削除を行う。

(2) また、判定結果である「YES」のあとに続く形でプロンプトで与えた答えを含む継続性判定例題が生成される場合があるため、プロンプトとは別に継続性判定例題の削除も行う。

(3) そして、プロンプト文などが含まれていない純粋な LLM の回答文を 3 種類に分類する。

(4) 回答文に「YES」という単語が含まれ、「NO」という単語が含まれない場合には継続判定とする。

(5) 次に、回答文に「NO」という単語が含まれ「YES」という単語が含まれない場合には非継続判定とする。

(6) 最後に「YES」と「NO」が両方の単語が含まれてしまっている場合や「YES」と「NO」が両方の単語が含まれてい

表 1: import リスト

ライブラリ名	version
transformers	4.33.1
pytorch	2.0.1
sqlite	3.41.2

ない場合には判別不能判定とする。

(7) また、3 種類に分類する際にはその単語が含まれているかどうかで分類を行うため「Y,E,S」が含まれる「YEAH!!S」のような形の回答文が継続判定にならないようになっている。これらの手順を踏まえて LLM 回答文から判定結果のみの抽出を行う。

4 試作システム

提案手法を python コードによる 2 つのプログラムで実装する。実行環境は Anaconda を使用しバージョンは conda 23.7.3 である。また、Python のバージョンは 3.11.4 である。試作システムを実行する際に必要なライブラリは表 1 として示す。

本研究で提案する試作システムの流れを以降の節で説明する。会話文の抜き出しで 1 つのプログラム、プロンプトの作成、テキスト生成、LLM 回答文からの判定結果抽出で 1 つのプログラム合計 2 つのプログラムを作成した。

4.1 会話文の抜き出しプログラム

会話文の抜き出しプログラムは json 形式のテキストデータを入力とし、sqlite 形式のテキストデータに変換して出力するプログラムである。json 形式で収集した tweet データ群から、in_reply_to_status_id の値と id の値が一致する tweet の検索を行う。検索を行い、tweet データ群から一致した tweet データのみの抽出を行う。その際に検索される id の in_reply_to_status_id が NULL の tweet に限定した。そうすることで reply が 2 つで構成される文章ペアを抜き出さないようにした。検索して一致した際には検索される id の text を先行文、検索する in_reply_to_status_id の text を後続文として sqlite 形式で出力を行う。

4.2 会話継続判定プログラム

会話継続判定プログラムは sqlite 形式のテキストデータを入力とし、sqlite 形式のテキストデータを出力するプログラムである。4.1 の会話文抜きだしプログラムを用いて抜き出した文章ペアを入力とする。入力である文章ペアを用いてプロンプト文を作成する。複数の継続性判定例題をあらかじめ用意してそれらを組み合わせることでプロンプト文が自動的に作成されるようにする。

そして作成したプロンプト文と設定するハイパーパラメータを設定してテキスト生成を行う。テキスト生成を行う際には使用する LLM モデルのトークナイザーとモデルの読み込みを行ってから生成する。トークナイザーは Python の AutoTokenizer クラス、モデルは AutoModelForCausalLM クラスを利用して読み込みを行う。またテキスト生成を行うコードは PyTorch の

表 2: 使用 PC のスペック

部品	仕様	型番
CPU	AM4 8C16T	AMD Ryzen 7 5700X
RAM	128GB DDR4 3200	Crucial DDR4-3200 32GB x4
G/B	dGPU	GeForce RTX4060Ti 16GB

表 3: 実験した条件のパターン表

temperature\ 例題内容	継続のみ	非継続のみ	継続と非継続	計
0.1	5	5	2	12
0.3	5	5	2	12
0.5	5	5	2	12
0.7	5	5	2	12
計	20	20	8	48

torch.no_grad() 内に記述することで勾配の計算をしないように設定した。

テキスト生成後は LLM 回答文からプロンプト文と一致する箇所の削除を行う。次に削除後の LLM 回答文が YES のみか NO のみかそれ以外 (NULL) のどれかに分類する。最後に分類した結果を LLM の判定結果として sqlite 形式で出力する。

5 評価実験

5.1 実験目的

プロンプト内で与える例題の数や種類を変えて会話の継続性判定への影響を調査を行い、LLM において本研究で設定する 4 組のパラメータの組から有効性を検証することを目的として、tweet データを利用して判別実験と性能評価を行う。

5.2 実験手順概要

実験用のデータセットは存在しないため、正解ラベルを付与することを含めて tweet データからデータセットを作成した。これを 4 章の試作システムを用いて判定結果を得て、正解と比較することで性能調査を行う。このとき、5.6 節で述べたハイパーパラメータが与える影響を検証するため、複数の値による判定結果を比較する。

5.3 実験環境

実験に使用した PC のスペックは表 2 に示す。また、OS は Ubuntu22.04LTS を使用した。実験で temperature や例題の内容や数を変えて行ったパターンをまとめた表として表 3 を示す。

5.4 使用したモデル

本研究では Xwin-LM-13B-V0.1 [6] を使用した。ローカル環境でテキストを生成する上で実行出来るモデルの内、最もパラメーター数の高かったこのモデルを選出した。

5.5 データセットの作成

まず、抽出した tweet データを格納するためのデータベースを sqlite 形式で作成した。

表 4: データセット内訳

データ	継続 (件)	非継続 (件)	計 (件)
自然データ	486	14	500
人為データ	19	481	500
データセット全体	505	495	1000

次に 4.1 の会話文抜き出しプログラムを用いて tweet データの抽出を行う。研究室で streaming API で取得した tweet オブジェクトの JSON 形式の tweet データが保存されておりそれを利用する。2022 年 3 月 3 日, 3 月 4 日, 3 月 5 日の 3 日分についての抽出を行った。

格納する際に判定精度を高めるために不要な文の削除を行った。tweet に画像や動画などが含まれる際は URL が tweet 本文の末尾に存在するため, その URL を削除した。また, 後続文には連続 tweet 以外は reply 元であるユーザーの id が tweet 本文の先頭に来るためこれも削除した。それ以外のユーザー id は削除すると文脈に違和感のある文章になってしまう可能性があるため削除は行わなかった。

その後, 格納した先行文と後続文を手手で会話が継続しているかしていないかの判断を行い取得順 500 件分に対しての正解ラベルを付けた。正解ラベルの付与は筆者一人で行い話題が継続していないものを非継続, 話題が継続しているもしくは判断が難しいものについては継続のラベルを付与した。この 500 件のデータを自然データと呼ぶ。

また, 取得した tweet は基本話題が継続していると考え, 先程の 500 件に含まれていない文章ペアから先行文と後続文をランダムに 500 件組み合わせる新たに文章ペア 500 件を作成した。最後に, 新たに作成した文章ペア 500 件に対しても先ほどと同様に正解ラベルの付与を行った。この 500 件のデータを人為データと呼ぶ。

データセットの内訳を表 4 として示す。データセット内の正解ラベルにはそれぞれ人手で判断した会話が継続している場合の YES, 継続していない場合の NO の 2 種類のうちのどちらかが与えられている。

5.6 会話継続判定

会話継続判定は 4.2 の会話継続判定プログラムを用いて判定する。本実験では temperature の値は 0.1 から 0.7 まで 0.2 ずつ変化させて実験する。次に 1 つのパラメータ組につき変える例題のパターンを説明する。まず表 5 からランダムに 1~5 個取りだし継続性判定例題数がそれぞれ 15 個の計 5 個のパターンのプロンプトを作成した。同様に表 6 からランダム 1~5 個取りだし非継続性判定例題数がそれぞれ 15 個の計 5 個のパターンのプロンプトを作成した。最後に表 5 からランダムに 1 個, 表 6 からランダムに 1 つ合計 2 個の例題を含むプロンプト, 表 5 からランダムに 2 個, 表 6 からランダムに 2 個合計 4 個の例題を含む計 2 個のパターンのプロンプトを作成した。つまり 1 個のパラメータ組につき 12 個のパターンのプロンプトを作成した。またプロンプト内で与える例題の内容による影響を減らす




図 3: temperature の比較

ため 1 つのパターンにつき例題内容が被らないように 3 個のプロンプトを作成した。そしてほかの 3 つのパラメータ組についても同様の手順でプロンプトを作成したため合計 192 個のプロンプトを作成した。この作成したプロンプトを用いて会話継続性判定を行う。

5.7 結果集計と正答率の算出

判定器からの出力結果をデータセットの正解ラベルと照合し, 正解率などの集計を行う。このとき, 出力結果には判定不能である場合が含まれるため, これは別に集計する。試作システムの 4.2 より LLM による判定結果を得たあと正解ラベルとの比較を行い比較結果を得た。正解ラベルとの比較を行った結果は以下の 3 つのパターンに分類される。

- (1) LLM の判定結果と正解ラベルが一致していた場合の判定成功
 - (2) LLM の判定結果と正解ラベルが一致していなかった場合の判定失敗
 - (3) LLM の判定結果が判別不能判定だった場合の判定不能
- そして集計結果から例題の種類毎に判定器の正答率を算出する。このときの正答率は判定成功数を全文書ペア数 (1000 件) で割って算出した。同様に例題の種類は同じだが例題内容が異なる 2 つについても正答率を算出する。得られた 3 つの正答率の平均を取り, 平均正答率を算出した。この平均正答率を他のパターンについても同様に算出し, この平均正答率を用いて評価を行う。

5.8 結果

temperature の値を変更した際の平均正答率を比較した図として, 図 3 を示す。この結果は 1 つの temperature の値につき 12 パターン算出した平均正答率からさらに平均を取り, temperature の値全体での平均正答率を算出した。

例題の種類を変更した際の平均正答率を比較した図として, 図 4 と図 5 を示す。図 4 は算出した 48 パターンのうち同一の例題内容毎でさらに平均を取って平均正答率を算出した結果である。また, 図 5 は算出した 48 パターンのうち例題数毎でさらに平均をとって平均正答率を算出した結果である。

5.9 temperature の値に関する考察

図 3 より temperature の値を 0.1 から 0.7 まで 0.2 ずつ変えて

表 5: 正判定例一覧

番号	判定例 (先行文)	判定例 (後続文)
1	ブチャラティ、おかっぱのくせにかっこよすぎるな	そりゃ世界一かっこいいおかっぱだから
2	もーほんとにワンピース買いきり引きこもりのくせに	どこも行かないのにわたしも買っちゃう
3	カップヌードルのにんにく豚骨美味しかったのでオススメ !!!!	おいしそー
4	インスタ繋がってない子繋がろーぜー !!!!	繋がりたいです！
5	マンガ読みたいけど、眠いから寝るおやすみ～！	おやすみ！
6	8 連勤がようやく終わった	おつつおつつですぞお！
7	ふっかさん、まさかの天然 www	まあ、それで言うと阿部ちゃんに限って『アイドルの引き出しが切れる』とか無いと思うので、有吉さんの言うとおりでなとは思っていた (笑)
8	腰痛のためお休みです。椅子に座れる状態でないため	ゆっくり休んで下さいね !! お大事に
9	ショールームありがとうございました	配信お疲れ様
10	あと気になってんのはチェンソーマンとブルーロックとカッコウの許嫁とピースターズ、と、DB	いっぱいですね ブルーロックは今年アニメもあるから気になってます!!

表 6: 負判定例一覧

番号	判定例 (先行文)	判定例 (後続文)
1	最近毎日何かしらで寝落ちてる自分を恨む	保証大丈夫やた？
2	お仕事終わったので帰ります…	ゴルフ沼へようこそ笑
3	連絡をして、返事を待っている状態です。もうしばらくお待ちください	ジャンプ力ヤバいそして可愛い
4	家ついちゃ	まさかのパワー 12 !? w
5	昨日の昼～今日の昼までろくな食事をしてなかったので、夜はいいもの食べた	私は RIZINLIVE で買ったよ
6	梅田のランワン来たけどやっぱり人多いな	ゆっくり休んで下さいね !! お大事に
7	中学のめっちゃ可愛い子から連絡きた	早く良くなりますように！ゆっくりしてくださいね
8	え、本当に妊娠してた。どうしょ！嬉しい！アメリカでの妊娠、大丈夫か私	肉じゃが食べたい
9	久しぶりにアニメ見たいな おすすめのアニメありますか？	本番中にダメ出し (笑)
10	産まれました !! 風船飛んでるの嬉しい	事前に入力できますよ !!




図 4: 例題内容比較




図 5: 例題数比較

実験したが、平均正答率に変化はみられなかった。本実験では別に設定したハイパーパラメータである max_new_tokens を 10 に設定しており、10 トークン以上のテキストが生成されないように制限していた。また、プロンプトでは回答は「YES」か「NO」のどちらかになるように指示していた。このことから生成させるテキストのトークン数を制限し、回答の形式をプロンプト内で指示していれば temperature による影響は小さいと考える。

また、今回の実験では temperature を変えたことによる大き

な変化は見られなかったが、平均正答率の観点から temperature が 0.1 のときに会話継続判定において有効であると考える。

5.10 例題内容に関する考察

図 4 から例題の内容を変えた場合には平均正答率に違いがみられた。話題が継続していない (非継続) 例題のみの条件のときに最も平均正答率が高く、話題が継続している (継続) 例題のみの条件のときに最も平均正答率が低かった。本実験では正解

ラベルの付与を明らかに話題が継続していないやりとりを非継続、話題が継続しているもしくは判断が難しいやりとりに関しては継続という判断基準のもと筆者一人で行った。そのため非継続の例題を与えた条件のほうが継続した例題を与えた条件よりもデータセットに即した判断基準になっており平均正答率が高くなったと考える。また、継続の例題と非継続の例題を混ぜた場合では継続の例題によって判断基準があいまいになったため非継続のみの例題のときと比べて平均正答率が低くなったと考える。

5.11 例題数に関する考察

図5から例題の数を変えた場合でも平均正答率に違いがみられた。非継続の例題では例題数が増加すると平均正答率も増加し、それ以外では例題数が増加すると平均正答率が減少した。このことや5.10から例題がタスクに適していないと例題数を増加させることで判断基準がよりあいまいになり、悪影響になってしまっていると考え。また、GPUのメモリの関係上例題数を増やすとプロンプトの文量が増え実装が困難になる。そのためこれ以上の例題数の増加は見込めないためshot文以外のプロンプト記法を検討する必要があると考える。

6 おわりに

本論文ではLLMを用いて、会話の主題が同一なのか転換されたのかを判定することを目的とした。この目的から本論文では複数の会話文から文章ペアに変換する前処理や、LLMのハイパーパラメータの設定とプロンプトの作成手順、LLMの回答文から判定部分のみの抽出方法を提案した。LLMのハイパーパラメータであるtemperatureの値やプロンプトで与える例題の種類や数を変えて計48パターン分の会話継続判定を行った。この結果temperatureによる会話継続判定への影響は小さかったが、本実験で設定したtemperatureの値の中で最も小さかった0.1が平均正答率が最も高かったため会話継続判定において有効であることがわかった。また、例題の種類による影響が高くなりそれに応じて例題数による影響も高まることが分かった。今後はshot文より会話継続判定に適したプロンプト記法の調査や、3回以上のやりとりに着目した会話継続判定での実験が必要であると考えている。

文 献

- [1] 東中 竜一郎, 船越 孝太郎, 小林 優佳, 稲葉 通将, “対話破綻検出チャレンジ,” 第75回言語・音声理解と対話処理研究会(第6回対話システムシンポジウム), 人工知能学会研究資料SIG-SLUD-75-B502 巻, pp.27-32, 2016.
- [2] 稲葉 通将, 高橋 健一, “Long Short-Term Memory Recurrent Neural Networkを用いた対話破綻検出,” 第78回言語・音声理解と対話処理研究会, SIG-SLUD, Vol. B5, No. 02, pp.57-60, 2015.
- [3] 田中 涼太, 李 晃伸, “Quasi-Recurrent Neural Networksに基づく対話モデルを用いた対話破綻検出,” 2018年度人工知能学会全国大会論文集(第32回), 2018.
- [4] 藤田 俊之, 小林 亜樹, “マイクロブログにおける会話を利用した災害情報採取手法,” 電子情報通信学会論文誌B, J106-B(1), pp.1-12, 2023-01-01.
- [5] “Few-Shot プロンプティング”, <https://www.promptingguide.ai/jp/techniques/fewshot>(参照日 2024-1-9)

- [6] “Xwin-LM-13B-V0.1”, <https://huggingface.co/Xwin-LM/Xwin-LM-13B-V0.1>(参照日 2024-1-9)